

Veri Boru Hattı ve Özellik Mühendisliği

Ti-6Al-4V Çimentosuz Kalça İmplantı için Surrogate ML Modeli

Ata Bulut
Bilgisayar Mühendisliği · 220901582

Mayıs 2026
ENS003 — Digital Twins for Health Sciences · Eğitmen: Prof. Dr. Şenol Pişkin

Bu sunumda

- Mekanik mühendisliği ekibinden gelen ham FEA verisini ML için tüketilebilir hale getirme süreci
- ANSYS export'undan `data/dataset.csv`'ye giden boru hattı
- `convert.py` ve `preprocess.py` mimarisi
- Karşılaştığım hatalar, test ve kapsam (*coverage*)

Sorumluluğum (yazılım ekibi)

Veri dönüştürme, şema tasarımı, feature engineering ve CV gruplandırma yardımcısı.

Veri kaynağı

ANSYS Workbench parametric Design Point sweep:

- $m \in \{50, 60, 70, 80, 90, 100\}$ kg (6 değer)
- $K \in \{2, 2.5, \dots, 6\}$ (9 değer, vücut ağırlığı katsayısı)
- $\theta \in \{0^\circ, 10^\circ, 20^\circ\}$ (3 değer, kuvvet eğim açısı)

$$6 \times 9 \times 3 = 162 \text{ benzersiz tasarım noktası}$$

ANSYS bunlardan 108'ini proje güncellemesinden sonra yeniden çalıştırmış — toplam 270 satır. Tekrarlar 5–6. ondalıkta farklı (çözücü mikro-gürültüsü).

Karar: 270 satırın hepsini tut

Her ANSYS çözümü pahalı; atmak savurganlık. Train-test leakage'ı önlemek için cross-validation (m, K, θ) üzerinden gruplandı — tekrarlar her zaman aynı fold'da.

```
def convert(source=None, out=None):
    src = source if source else _pick_source(prefer_csv=True)
    if src.suffix.lower() == ".csv":
        raw = _read_csv(src)          # 7 sat. preamble atla
    else:
        raw = _read_xlsx(src)         # "Units" satirini drop

    df = _normalize_columns(raw)      # P1 ya da "P1 - Force..."
    df = pd.to_numeric(...).dropna()
    df = _convert_units(df)          # MPa -> Pa, mm -> m
    df = _attach_constants(df, ModelConstants())
    df["case_id"] = [f"DP_{i+1:03d}" for i in range(len(df))]
    df.to_csv(out, index=False)
    return df
```

- İki kaynak formatı: CSV (preamble + bare P1) ve XLSX (Units satırı + P1 - Force X Component)
- Tek regex `^\s*(P\d+)\b` iki formatı da yakalar
- Birim normalizasyonu: MPa→Pa, mm→m
- ANSYS sabitleri (mesh, malzeme) ModelConstants'tan satırlara

preprocess.py: özellik mühendisliği

```
INPUT_FEATURES = ["patient_mass_kg", "K_factor", "force_angle_deg"]
DERIVED_FEATURES = ["force_x_N", "force_z_N", "force_magnitude_N"]

def add_features(df):
    out = df.copy()
    rad = np.deg2rad(out["force_angle_deg"])
    Fmag = out["patient_mass_kg"] * 9.81 * out["K_factor"]
    out["force_x_N"] = Fmag * np.cos(rad)
    out["force_z_N"] = Fmag * np.sin(rad)
    out["force_magnitude_N"] = Fmag
    return out
```

- Model 3 bağımsız girdi görüyor: m, K, θ
- $F_x, F_z, |F|$ bu üçünden **analitik** türev — predict ile train aynı formüle bağlı, drift yok
- F_y ve `fixed_support_n_faces` tüm satırlarda sabit (varyans = 0) $\Rightarrow$ girdiden düşürüldü

CV gruplandırma — `grid_groups()`

```
GRID_KEYS = ("patient_mass_kg", "K_factor", "force_angle_deg")

def grid_groups(df):
    """Return a group ID per row, equal for ANSYS re-runs."""
    grouped = df[list(GRID_KEYS)].astype(str).agg("|".join, axis=1)
    return grouped.to_numpy()
```

Recep'in `train.py`'da kullanımı:

- `GroupKFold(n_splits=5).split(X, y, groups=grid_groups(df))`
- Aynı (m, K, θ) üçlüsü her zaman aynı fold'da
- Olmasaydı: R^2 yapay olarak ≈ 1.0 'a şişerdi (leakage)

Yol boyu karşılaştığım hatalar

- **XLSX'in "Units" satırı:** İlk veri satırı aslında birim etiketi (kg, MPa, mm, ...) — pandas tüm sütunu object dtype yaptı, sayısal işlemler çöktü. **Çözüm:** satırı drop + `pd.to_numeric(errors='coerce')`
- **İki başlık formatı:** CSV'de P1, XLSX'te P1 - Force X Component. **Çözüm:** regex `*(P+)_` ile her ikisini yakalayante parser.
- **out=OUT_CSV varsayılan argümanı:** Python'da fonksiyon tanım zamanında bağlandığı için test'lerde monkeypatch işe yaramıyordu $\Rightarrow$ data/dataset.csv gerçek dosyaya yazıyordu. **Çözüm:** out=None + runtime resolve.

Test & kapsam

Dosya	İfade sayısı	Kapsam
<code>src/convert.py</code>	115	90%
<code>src/preprocess.py</code>	27	100%

Önemli test senaryoları:

- Immutability: `add_features()` input DataFrame'i mutate etmiyor
- Trigonometri: $F_x^2 + F_z^2 = |F|^2$ her satır için
- Eski F_x/F_z sütunları üzerine yazılıyor (predict-time tutarlılık)
- ANSYS re-run'ları aynı `grid_groups()` ID'sini paylaşıyor

Demo

```
$ ./run.sh convert
wrote 270 rows -> data/dataset.csv
total rows kept: 270 (unique grid points: 162)

$ ./run.sh check | head -6
rows=270    columns=30
unique grid points: 162
non-null target counts:
  safety_factor_neck_min: 270 / 270
  ...
```

Çıktı, Recep'in `train.py`'ına doğrudan beslenebilir durumda. Şema, modelleme tarafıyla **tek bir doğruluk kaynağı**'nda buluşuyor.

Teşekkürler.

Sorular?

- `src/convert.py`, `src/preprocess.py`
- `tests/test_preprocess.py` (12 test, 100% coverage)
- Geliştirme logu: `docs/PROJECT_NOTES.md` Sprint 1–2